

NosAnalizamos

Tu Nombre

2026-05-24

Contents

1	Instalacion y carga de librerias	2
2	Carga de datos	2
3	Eliminar usuario martsobm	5
4	Seleccion y limpieza de calificaciones	5
5	Tabla de estadisticos	5
6	ggpairs: relaciones entre variables	5
7	Matrices de correlacion y covarianza	7
8	Boxplots de calificaciones	8
9	Boxplots por sexo	9
10	Alumnos con calificaciones en todas las asignaturas	10
11	Comparacion 2022 vs 2026	11
12	Preguntas con datos 2026	12
12.1	Alumno mas joven a 01/02/2026	12
12.2	Alumnos que simultanean trabajo y estudios	12
12.3	Fumadores por sexo	12
12.4	Media y varianza de Wr.Hnd segun sexo	13
12.5	Relacion entre sexo y mano con la que se escribe (NW.Hnd)	13
12.6	Relacion lineal entre Height y Wr.Hnd	13
12.7	Outliers en altura (identificador de Hampel)	15
12.8	Imputacion generalizada de FP con la media	15
12.9	Imputacion de FP segun PulseCat	15
12.10	Relacion entre Pulse y calificaciones en ALG	16

1 Instalacion y carga de librerias

2 Carga de datos

Carga el fichero de datos en R y llama `datos` al data frame obtenido. Este data frame contiene solo las columnas con variables y las filas con datos. La fila de cabecera se detecta de forma automatica y por eso el mismo codigo sirve para 2022 y 2026 sin cambios.

```
find_header_row <- function(path, header = "FechaNac(DD-MM-YYY)") {
  lines <- read_lines(path, n_max = 200)
  header_row <- which(str_detect(lines, fixed(header)))[1]
  if (is.na(header_row)) {
    stop("No se encontro la fila de cabecera")
  }
  header_row
}

cargar_datos <- function(path) {
  header_row <- find_header_row(path)
  datos <- read_delim(
    path,
    skip = header_row - 1,
    delim = "\t",
    trim_ws = TRUE,
    show_col_types = FALSE
  )
  datos <- datos %>% filter(!is.na(Id) & Id != "")
  datos
}

to_numeric <- function(x) {
  x <- str_trim(as.character(x))
  x <- str_replace_all(x, ",", ".")
  x[x == ""] <- NA_character_
  as.numeric(x)
}

limpiar_nota <- function(x) {
  x <- str_trim(as.character(x))
  x <- str_replace_all(x, ",", ".")
  x <- ifelse(str_to_upper(x) == "NC", "3", x)
  valido <- str_detect(x, "^\\d+(\\.\\d+)?$")
  x[!valido] <- NA_character_
  as.numeric(x)
}

limpiar_notas <- function(df, asignaturas) {
  df %>% mutate(across(all_of(asignaturas), limpiar_nota))
}

normalizar_sexo <- function(x) {
  x <- str_to_lower(str_trim(as.character(x)))
  x <- case_when(
```

```

  x %in% c("m", "masculino", "hombre") ~ "M",
  x %in% c("f", "femenino", "mujer") ~ "F",
  TRUE ~ NA_character_
)
factor(x, levels = c("F", "M"), ordered = TRUE)
}

normalizar_mano <- function(x) {
  x <- str_to_lower(str_trim(as.character(x)))
  x <- case_when(
    x %in% c("derecha", "der", "right") ~ "Derecha",
    x %in% c("izquierda", "izq", "left") ~ "Izquierda",
    TRUE ~ NA_character_
  )
  factor(x, levels = c("Derecha", "Izquierda"), ordered = TRUE)
}

normalizar_fuma <- function(x) {
  x <- str_to_lower(str_trim(as.character(x)))
  x <- iconv(x, to = "ASCII//TRANSLIT")
  x <- case_when(
    x %in% c("si", "s") ~ "Si",
    x %in% c("no", "n") ~ "No",
    TRUE ~ NA_character_
  )
  factor(x, levels = c("No", "Si"), ordered = TRUE)
}

limpiar_personales <- function(df) {
  if ("Sex" %in% names(df)) {
    df$Sex <- normalizar_sexo(df$Sex)
  }
  if ("NW.Hnd" %in% names(df)) {
    df$NW.Hnd <- normalizar_mano(df$NW.Hnd)
  }
  if ("Smoke" %in% names(df)) {
    df$Smoke <- normalizar_fuma(df$Smoke)
  }
  if ("Wr.Hnd" %in% names(df)) {
    df$Wr.Hnd <- to_numeric(df$Wr.Hnd)
  }
  if ("Height" %in% names(df)) {
    df$Height <- to_numeric(df$Height)
  }
  if ("Pulse" %in% names(df)) {
    df$Pulse <- to_numeric(df$Pulse)
  }
  if ("Hwork" %in% names(df)) {
    df$Hwork <- to_numeric(df$Hwork)
  }
  if ("HSt" %in% names(df)) {
    df$HSt <- to_numeric(df$HSt)
  }
}

```

```

if ("Age" %in% names(df)) {
  df$Age <- to_numeric(df$Age)
}
if ("FechaNac(DD-MM-YYY)" %in% names(df)) {
  df$FechaNac <- dmy(df[["FechaNac(DD-MM-YYY)"]], quiet = TRUE)
}
df
}

preparar_datos <- function(path, asignaturas) {
  datos <- cargar_datos(path)
  datos <- datos %>% filter(Id != "martsobm")
  datos <- limpiar_personales(datos)
  datos <- limpiar_notas(datos, asignaturas)
  datos
}

tabla_estadisticos <- function(datos, asignaturas) {
  datos %>%
    summarise(across(all_of(asignaturas), list(
      min = ~ min(., na.rm = TRUE),
      p25 = ~ quantile(., 0.25, na.rm = TRUE),
      mediana = ~ median(., na.rm = TRUE),
      media = ~ mean(., na.rm = TRUE),
      sd = ~ sd(., na.rm = TRUE),
      p75 = ~ quantile(., 0.75, na.rm = TRUE),
      max = ~ max(., na.rm = TRUE)
    ))) %>%
    pivot_longer(cols = everything(), names_to = "nombre", values_to = "valor") %>%
    separate(nombre, into = c("asignatura", "stat"), sep = "_") %>%
    pivot_wider(names_from = stat, values_from = valor) %>%
    select(asignatura, min, p25, mediana, media, sd, p75, max) %>%
    mutate(across(-asignatura, ~ round(., 2)))
}

max_correlaciones <- function(mat) {
  mat[lower.tri(mat, diag = TRUE)] <- NA
  max_abs <- max(abs(mat), na.rm = TRUE)
  idx <- which(abs(mat) == max_abs, arr.ind = TRUE)
  tibble(
    var1 = rownames(mat)[idx[, 1]],
    var2 = colnames(mat)[idx[, 2]],
    correlacion = mat[idx]
  )
}

asignaturas <- c("ALG", "ANM", "FP", "DCS", "MD")
path_2022 <- "data/NosAutoanalizamos2022 - Hoja1.tsv"
datos <- preparar_datos(path_2022, asignaturas)

```

```

## New names:
## * ' ' -> '...1'

```

3 Eliminar usuario martsobm

Elimina al usuario cuyo id es `martsobm` del conjunto de datos.

```
datos <- datos %>% filter(Id != "martsobm")
datos %>% filter(Id == "martsobm")

## # A tibble: 0 x 22
## #   i 22 variables: ...1 <chr>, FechaNac(DD-MM-YYY) <chr>, Id <chr>, Age <dbl>,
## #     Sex <ord>, Wr.Hnd <dbl>, NW.Hnd <ord>, Fold <chr>, Pulse <dbl>, Clap <chr>,
## #     Exer <dbl>, Smoke <ord>, Height <dbl>, ALG <dbl>, ANM <dbl>, FP <dbl>,
## #     DCS <dbl>, MD <dbl>, HSt <dbl>, Hwork <dbl>, Comentarios <chr>,
## #     FechaNac <date>
```

4 Selecccion y limpieza de calificaciones

Selecciona las columnas con las calificaciones y adécualas para que, al transformar a tipo numerico, los valores sean correctos (separador decimal con punto). Si alguna calificacion es NC se sustituye por 3. Cualquier otro valor no reconocible se sustituye por NA.

```
notas <- datos %>% select(all_of(asignaturas))
save(notas, file = "Notas.Rdata")
```

5 Tabla de estadisticos

Obtén una tabla de estadisticos de estas variables, donde en la primera columna aparezca cada asignatura y las siguientes columnas se correspondan con: valor minimo, percentil 25, mediana, valor medio, desviacion tipica, percentil 75, valor maximo. Resultados con 2 decimales.

```
stats_table <- tabla_estadisticos(datos, asignaturas)
knitr::kable(stats_table)
```

asignatura	min	p25	mediana	media	sd	p75	max
ALG	1.9	6.00	6.72	6.41	1.65	7.50	10.00
ANM	3.4	6.97	7.90	7.61	1.45	8.50	9.81
FP	3.0	3.53	6.00	5.77	2.25	7.25	9.50
DCS	3.0	6.79	7.65	7.42	1.36	8.30	9.80
MD	1.5	5.47	6.40	6.12	1.99	7.41	9.50

6 ggpairs: relaciones entre variables

Usa `ggpairs` de la libreria `GGally` y representa las relaciones entre las calificaciones.

```
GGally::ggpairs(datos %>% select(all_of(asignaturas)))
```

```
## Warning: Removed 2 rows containing non-finite outside the scale range
## ('stat_density()').
```

```

## Warning: Removed 2 rows containing missing values

## Warning: Removed 42 rows containing missing values

## Warning: Removed 2 rows containing missing values
## Removed 2 rows containing missing values

## Warning: Removed 2 rows containing missing values or values outside the scale
## range ('geom_point()').

## Warning: Removed 2 rows containing non-finite outside the scale range
## ('stat_density()').

## Warning: Removed 42 rows containing missing values

## Warning: Removed 2 rows containing missing values
## Removed 2 rows containing missing values

## Warning: Removed 42 rows containing missing values or values outside the scale range ('geom_point()')
## Removed 42 rows containing missing values or values outside the scale range ('geom_point()').

## Warning: Removed 42 rows containing non-finite outside the scale range
## ('stat_density()').

## Warning: Removed 42 rows containing missing values
## Removed 42 rows containing missing values

## Warning: Removed 2 rows containing missing values or values outside the scale range ('geom_point()')
## Removed 2 rows containing missing values or values outside the scale range ('geom_point()').

## Warning: Removed 42 rows containing missing values or values outside the scale
## range ('geom_point()').

## Warning: Removed 2 rows containing non-finite outside the scale range
## ('stat_density()').

## Warning: Removed 2 rows containing missing values


## Warning: Removed 2 rows containing missing values or values outside the scale range ('geom_point()')
## Removed 2 rows containing missing values or values outside the scale range ('geom_point()').

## Warning: Removed 42 rows containing missing values or values outside the scale
## range ('geom_point()').

## Warning: Removed 2 rows containing missing values or values outside the scale
## range ('geom_point()').

## Warning: Removed 2 rows containing non-finite outside the scale range
## ('stat_density()').

```



7 Matrices de correlacion y covarianza

Determina las matrices de correlacion y covarianza de las calificaciones con las opciones “Spearman” y “Pearson”, e indica que pares de variables tienen la correlacion mas alta.

```
datos_notas <- datos %>% select(all_of(asignaturas))

cor_pearson <- cor(datos_notas, method = "pearson", use = "pairwise.complete.obs")
cor_spearman <- cor(datos_notas, method = "spearman", use = "pairwise.complete.obs")
cov_matrix <- cov(datos_notas, use = "pairwise.complete.obs")

max_pearson <- max_correlaciones(cor_pearson)
max_spearman <- max_correlaciones(cor_spearman)

cor_pearson
```

```
##          ALG          ANM          FP          DCS          MD
## ALG 1.0000000 0.7496902 0.5506998 0.4892651 0.6654584
## ANM 0.7496902 1.0000000 0.6146760 0.5991354 0.6214427
## FP  0.5506998 0.6146760 1.0000000 0.5057321 0.7220793
## DCS 0.4892651 0.5991354 0.5057321 1.0000000 0.4954562
## MD  0.6654584 0.6214427 0.7220793 0.4954562 1.0000000
```

```
cor_spearman
```

```
##           ALG           ANM           FP           DCS           MD
## ALG 1.0000000 0.6800374 0.6183589 0.5609870 0.7225803
## ANM 0.6800374 1.0000000 0.6997607 0.6457497 0.6790033
## FP  0.6183589 0.6997607 1.0000000 0.4577758 0.7283962
## DCS 0.5609870 0.6457497 0.4577758 1.0000000 0.5952220
## MD  0.7225803 0.6790033 0.7283962 0.5952220 1.0000000
```

```
cov_matrix
```

```
##           ALG           ANM           FP           DCS           MD
## ALG 2.729793 1.796924 2.030932 1.102668 2.183312
## ANM 1.796924 2.104582 1.886942 1.185615 1.790252
## FP  2.030932 1.886942 5.080105 1.697395 2.773605
## DCS 1.102668 1.185615 1.697395 1.860680 1.342058
## MD  2.183312 1.790252 2.773605 1.342058 3.943302
```

```
max_pearson
```

```
## # A tibble: 1 x 3
##   var1 var2 correlacion
##   <chr> <chr>      <dbl>
## 1 ALG   ANM         0.750
```

```
max_spearman
```

```
## # A tibble: 1 x 3
##   var1 var2 correlacion
##   <chr> <chr>      <dbl>
## 1 FP   MD         0.728
```


8 Boxplots de calificaciones

Representa en una misma grafica los boxplots con las calificaciones obtenidas en las diferentes asignaturas.

```
notas_long <- datos %>%
  select(all_of(asignaturas)) %>%
  pivot_longer(cols = everything(), names_to = "asignatura", values_to = "nota")

ggplot(notas_long, aes(x = asignatura, y = nota, fill = asignatura)) +
  geom_boxplot() +
  theme(legend.position = "none", axis.text.x = element_text(angle = 45, hjust = 1)) +
  labs(title = "Boxplots de calificaciones", x = "Asignatura", y = "Nota")
```

```
## Warning: Removed 50 rows containing non-finite outside the scale range
## ('stat_boxplot()').
```

9 Boxplots por sexo


Añade la variable sexo al conjunto de datos y realiza la representación del boxplot de calificaciones por asignatura coloreando según dicha variable.

```
datos <- datos %>% mutate(sexo = Sex)

notas_sexo_long <- datos %>%
  select(sexo, all_of(asignaturas)) %>%
  pivot_longer(cols = all_of(asignaturas), names_to = "asignatura", values_to = "nota")

ggplot(notas_sexo_long, aes(x = asignatura, y = nota, fill = sexo)) +
  geom_boxplot() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  labs(title = "Boxplots por sexo", x = "Asignatura", y = "Nota", fill = "Sexo")
```

```
## Warning: Removed 50 rows containing non-finite outside the scale range
## ('stat_boxplot()').
```




10 Alumnos con calificaciones en todas las asignaturas

Selecciona los alumnos que tengan calificaciones en todas las asignaturas y representalas graficamente. En el eje X aparece el usuario (girado 90 grados) y en el eje Y la calificacion numerica con un color distinto para cada asignatura. Se muestra un diagrama de lineas y un punto por asignatura y alumno.

```
datos_completos <- datos %>%
  filter(if_all(all_of(asignaturas), ~ !is.na(.x))) %>%
  select(Id, all_of(asignaturas))

datos_long <- datos_completos %>%
  pivot_longer(cols = -Id, names_to = "asignatura", values_to = "nota")

ggplot(datos_long, aes(x = Id, y = nota, color = asignatura, group = asignatura)) +
  geom_line() +
  geom_point(size = 2) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 90, hjust = 1, vjust = 0.5)) +
  labs(
    title = "Calificaciones por alumno y asignatura",
    x = "Alumno",
    y = "Calificacion",
    color = "Asignatura"
  )
```



11 Comparacion 2022 vs 2026

Sin modificar el codigo, se usa el fichero de 2026 y se comparan los resultados con 2022.

```
path_2026 <- "data/NosAutoanalizamos2026 - NosAutoanalizamos (1).tsv"
datos_2026 <- preparar_datos(path_2026, asignaturas)
```

```
## New names:
## * '' -> '...22'
## * '' -> '...23'
```

```
stats_2026 <- tabla_estadisticos(datos_2026, asignaturas)
stats_2026
```

```
## # A tibble: 5 x 8
##   asignatura  min  p25 mediana media  sd  p75  max
##   <chr>      <dbl> <dbl>   <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 ALG        0.28  3      6.55  5.45  2.36  7.47  8.8
## 2 ANM        0.08  5.01   6.6   6.12  2.07  7.55  10
## 3 FP         0.8   3      3      4.4  2.39  7      8.6
## 4 DCS        3      4      7.1   6.11  2.18  8      9
## 5 MD        2.6   5.58   6.45  6.12  1.68  7.43  8.3
```

```
comparacion_medias <- tibble(
  asignatura = asignaturas,
  media_2022 = sapply(datos[asignaturas], mean, na.rm = TRUE),
  media_2026 = sapply(datos_2026[asignaturas], mean, na.rm = TRUE)
) %>%
  mutate(diferencia = round(media_2026 - media_2022, 2))

knitr::kable(comparacion_medias)
```

asignatura	media_2022	media_2026	diferencia
ALG	6.406000	5.454259	-0.95
ANM	7.606500	6.121600	-1.48
FP	5.770000	4.400000	-1.37
DCS	7.421000	6.107407	-1.31
MD	6.118333	6.125000	0.01

12 Preguntas con datos 2026

Responde a las preguntas usando datos 2026. Se corrigen valores invalidos: si no son M o F en **Sex**, o no son Derecha/Izquierda en **NW.Hnd**, se reemplazan por NA. Lo mismo para **Smoke**.

```
fecha_referencia <- ymd("2026-02-01")
datos_2026 <- datos_2026 %>%
  mutate(Edad_a_01_02_2026 = as.numeric(difftime(fecha_referencia, FechaNac, units = "days")) / 365.25)
```

12.1 Alumno mas joven a 01/02/2026

```
edad_mas_joven <- min(datos_2026$Edad_a_01_02_2026, na.rm = TRUE)
round(edad_mas_joven, 2)
```

```
## [1] 18.12
```

12.2 Alumnos que simultanean trabajo y estudios

```
alumnos_trabajo_estudios <- datos_2026 %>%
  filter(!is.na(Hwork) & Hwork > 0) %>%
  nrow()
alumnos_trabajo_estudios
```

```
## [1] 14
```

12.3 Fumadores por sexo

```
datos_fumadores <- datos_2026 %>%
  filter(Smoke == "Si") %>%
  count(Sex, name = "num_fumadores")
datos_fumadores
```

```
## # A tibble: 1 x 2
##   Sex   num_fumadores
##   <ord>         <int>
## 1 M             7
```

12.4 Media y varianza de Wr.Hnd segun sexo

```
datos_wr_hnd <- datos_2026 %>%
  group_by(Sex) %>%
  summarise(
    media_wr_hnd = mean(Wr.Hnd, na.rm = TRUE),
    varianza_wr_hnd = var(Wr.Hnd, na.rm = TRUE)
  )
knitr::kable(datos_wr_hnd)
```

Sex	media_wr_hnd	varianza_wr_hnd
F	18.04348	3.717115
M	19.98824	1.732585

12.5 Relacion entre sexo y mano con la que se escribe (NW.Hnd)

```
tabla_sexo_mano <- table(datos_2026$Sex, datos_2026$NW.Hnd, useNA = "no")
tabla_sexo_mano
```

```
##
##   Derecha Izquierda
##   F      22        2
##   M      29        7
```

```
chisq_test <- chisq.test(tabla_sexo_mano, correct = FALSE)
```

```
## Warning in chisq.test(tabla_sexo_mano, correct = FALSE): Chi-squared
## approximation may be incorrect
```

```
chisq_test$p.value
```

```
## [1] 0.2376743
```


12.6 Relacion lineal entre Height y Wr.Hnd

```
ggplot(datos_2026, aes(x = Height, y = Wr.Hnd)) +
  geom_point() +
  geom_smooth(method = "lm", se = FALSE, color = "blue") +
  labs(title = "Relacion entre Height y Wr.Hnd", x = "Height", y = "Wr.Hnd") +
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

```
## Warning: Removed 3 rows containing non-finite outside the scale range
## ('stat_smooth()').
```

```
## Warning: Removed 3 rows containing missing values or values outside the scale
## range ('geom_point()').
```



```
cor_pearson_height_wr_hnd <- cor(datos_2026$Height, datos_2026$Wr.Hnd, method = "pearson", use = "complete.obs")
cor_spearman_height_wr_hnd <- cor(datos_2026$Height, datos_2026$Wr.Hnd, method = "spearman", use = "complete.obs")
cor_pearson_height_wr_hnd
```

```
## [1] 0.4310869
```

```
cor_spearman_height_wr_hnd
```

```
## [1] 0.3347821
```

12.7 Outliers en altura (identificador de Hampel)

```
madm <- function(x, na.rm = TRUE) {  
  med <- median(x, na.rm = na.rm)  
  1.4826 * median(abs(x - med), na.rm = na.rm)  
}  
  
regla_hampel <- function(x) {  
  med <- median(x, na.rm = TRUE)  
  m <- madm(x, na.rm = TRUE)  
  x < (med - 3 * m) | x > (med + 3 * m)  
}  
  
datos_2026 <- datos_2026 %>%  
  mutate(outlier_height = regla_hampel(Height))  
  
outliers_height <- datos_2026 %>%  
  filter(outlier_height) %>%  
  select(Id, Height)  
  
outliers_height
```

```
## # A tibble: 0 x 2  
## # i 2 variables: Id <chr>, Height <dbl>
```

12.8 Imputacion generalizada de FP con la media

```
media_fp <- mean(datos_2026$FP, na.rm = TRUE)  
media_fp
```

```
## [1] 4.4
```

12.9 Imputacion de FP segun PulseCat

```
datos_2026 <- datos_2026 %>%  
  mutate(PulseCat = ifelse(Pulse >= 65, "PulseH", "PulseL"))  
  
media_fp_pulse <- datos_2026 %>%  
  group_by(PulseCat) %>%  
  summarise(media_fp = mean(FP, na.rm = TRUE))  
  
media_fp_pulse
```

```
## # A tibble: 3 x 2  
##   PulseCat media_fp  
##   <chr>      <dbl>  
## 1 PulseH      5.1  
## 2 PulseL      4.14  
## 3 <NA>        3
```


12.10 Relacion entre Pulse y calificaciones en ALG

```
ggplot(datos_2026, aes(x = Pulse, y = ALG)) +  
  geom_point() +  
  geom_smooth(method = "lm", se = FALSE, color = "blue") +  
  labs(title = "Relacion entre Pulse y ALG", x = "Pulse", y = "ALG") +  
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```

```
## Warning: Removed 8 rows containing non-finite outside the scale range  
## ('stat_smooth()').
```

```
## Warning: Removed 8 rows containing missing values or values outside the scale  
## range ('geom_point()').
```



```
cor_pearson_pulse_alg <- cor(datos_2026$Pulse, datos_2026$ALG, method = "pearson", use = "complete.obs")  
cor_spearman_pulse_alg <- cor(datos_2026$Pulse, datos_2026$ALG, method = "spearman", use = "complete.obs")  
cor_pearson_pulse_alg
```

```
## [1] 0.1419435
```



```
cor_spearman_pulse_alg
```

```
## [1] 0.08321638
```